

CLASIFICACIÓN Y REGRESIÓN EN DATASET DE PELÍCULAS

Marco
Pérez González

marco.perez
@alumnos.upm.es

David
Cano Rosillo

david.cano.rosillo
@alumnos.upm.es

José Javier
Román Camacho

josejavier.roman
@alumnos.upm.es

CLASIFICACIÓN Y REGRESIÓN EN DATASET DE PELÍCULAS

Datos


Procesado

Métricas

color	duration	vote averga	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating.
categoricos
color, language, country...
texto
keywords, overview,



Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$
Vector
DB

Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM

Predicción de género

	CV	TEST
ACC	0.92	0.27




Pósteres

2894 x .jpg

Imágen

matrix 3 x 224
x 244



Pre-trained resnet + finetuning

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$

OPTUNA



Datos


Procesado

Métricas

color	duration	vote averga	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating,
categoricos
color, language, country...



Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

Datos


Procesado

Métricas

color	duration	vote average	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating,
categoricos
color, language, country...




Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

Ingeniería de características

- Variables asociadas a los directores (LOO target encoding)
- Variables asociadas a longitudes (del reparto, descripciones, etc)
- Proporciones de likes en facebook (película, actores, etc)



Datos

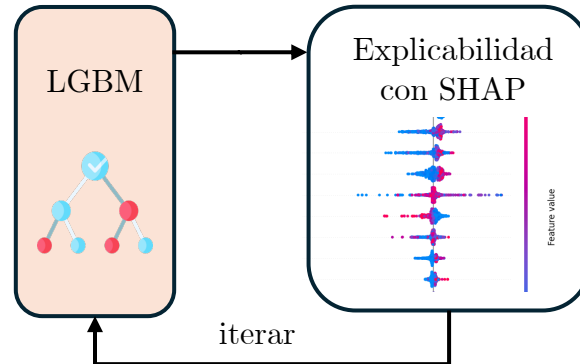
Procesado

Métricas

color	duration	vote average	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating,
categoricos
color, language, country...


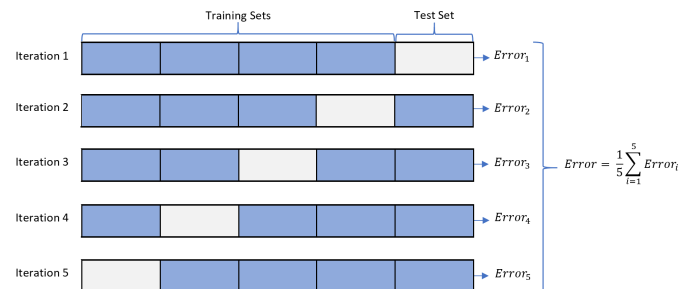


Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

Ingeniería de características

- Variables asociadas a los directores (LOO target encoding)
- Variables asociadas a longitudes (del reparto, descripciones, etc)
- Proporciones de likes en facebook (película, actores, etc)



CLASIFICACIÓN Y REGRESIÓN EN DATASET DE PELÍCULAS

Datos


Procesado

Métricas

color	duration	vote averga	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating.
categoricos
color, language, country...
texto
keywords, overview,



Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$
Vector
DB

Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM

Predicción de género


	CV	TEST
ACC	0.92	0.27



Pósteres
2894 x .jpg

Imágen

matrix 3 x 224
x 244



Pre-trained resnet + finetuning

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM

OPTUNA
⚡⚡

CLASIFICACIÓN Y REGRESIÓN EN DATASET DE PELÍCULAS

Datos

Procesado

Métricas

color	duration	vote averga	keywords

Datos tabulares
2896 películas

numéricos
duration,
content_rating.

categoricos
color, language,
country...

texto
keywords,
overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$
Vector
DB

Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM

Predicción de género


	CV	TEST
ACC	0.92	0.27



Pósteres
2894 x .jpg

Imágen

matrix 3 x 224
x 244



Pre-trained resnet + finetuning

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$

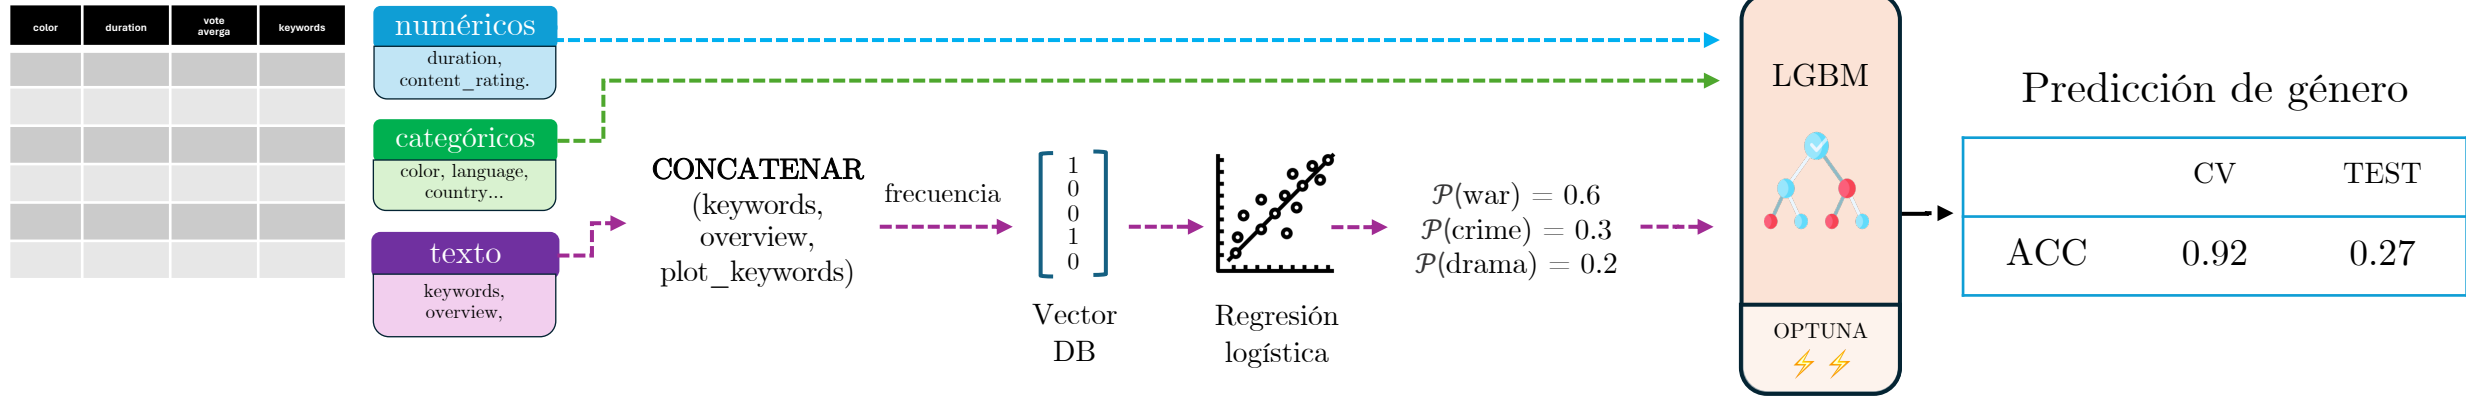
OPTUNA



Datos

Procesado

Métricas



Datos

Procesado

Métricas

color	duration	vote averga	keywords

numéricos

duration,
content_rating.

categoricos

color, language,
country...

texto


keywords,
overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM



OPTUNA
⚡ ⚡

Predicción de género


	CV	TEST
ACC	0.92	0.27

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

color	duration	vote averga	keywords

numéricos

duration,
content_rating.

categoricos

color, language,
country...

texto


keywords,
overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM



OPTUNA
⚡ ⚡

Predicción de género


	CV	TEST
ACC	0.92	0.27

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

Cosas que no funcionaron

- BERT
- CountVectorizer


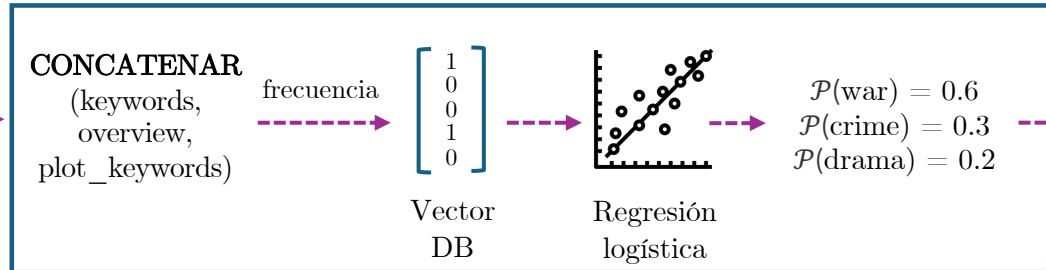
Datos

Procesado

Métricas


color	duration	vote averga	keywords

numéricos
duration, content_rating.
categoricos
color, language, country...
texto
keywords, overview,



Predicción de género

	CV	TEST
ACC	0.92	0.27



GENRE	AUC
Western	0.990389
War	0.985437
Horror	0.956172
Documentary	0.954239
Music	0.947796
Science Fiction	0.946767
History	0.929853
Animation	0.923654
Family	0.917338

GENRE	AUC
Crime	0.910368
Fantasy	0.890410
Action	0.888968
Romance	0.867276
Adventure	0.866570
Thriller	0.865806
Comedy	0.854768
Mystery	0.824911
Foreign	0.490550

color	duration	vote averga	keywords

numéricos

duration,
content_rating.

categoricos

color, language,
country...

texto


keywords,
overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia


$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$



Predicción de género


	CV	TEST
ACC	0.92	0.27

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

“ Nuestro objetivo es generar las mejores *features* para LGBM ”

Datos

Procesado

Métricas

color	duration	vote averga	keywords


numéricos
duration, content_rating.
categoricos
color, language, country...
texto
keywords, overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM




Predicción de género

	CV	TEST
ACC	0.92	0.27



Imagen
matrix 3 x 224
x 244



Pre-trained resnet + **finetuning**

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$


OPTUNA
⚡ ⚡

Pre-trained resnet + finetuning



Imágen

matrix 3 x 224 x 244



$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$



Datos

Procesado

Métricas

color	duration	vote average	keywords

numéricos
duration,
content_rating.

categoricos
color, language,
country...


texto
keywords,
overview,

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM




Predicción de género

	CV	TEST
ACC	0.92	0.27



Imagen

matrix 3 x 224
x 244



Pre-trained resnet + finetuning

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$

OPTUNA






$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$




$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$




Predicción de género

	CV	TEST
ACC	0.92	0.27


Adventure




Documentary




Adventure




Documentary




Adventure




Documentary




Adventure




Documentary



Adventure



Documentary



CLASIFICACIÓN Y REGRESIÓN EN DATASET DE PELÍCULAS

Datos


Procesado

Métricas

color	duration	vote averga	keywords

Datos tabulares
2896 películas

numéricos
duration, content_rating.
categoricos
color, language, country...
texto
keywords, overview,



output


Predicción de score

	CV	TEST
MAE	0.24	0.22
MSE	0.13	0.09

CONCATENAR
(keywords,
overview,
plot_keywords)

frecuencia

$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$
Vector
DB



Regresión
logística

$\mathcal{P}(\text{war}) = 0.6$
 $\mathcal{P}(\text{crime}) = 0.3$
 $\mathcal{P}(\text{drama}) = 0.2$


LGBM

Predicción de género

	CV	TEST
ACC	0.92	0.27

Imágen

matrix 3 x 224
x 244



Pre-trained resnet + finetuning

$\mathcal{P}(\text{war}) = 0.2$
 $\mathcal{P}(\text{crime}) = 0.4$
 $\mathcal{P}(\text{drama}) = 0.2$

LGBM

OPTUNA



Pósteres

2894 x .jpg